

安全帽检测及预警系统研究与实现

摘要

随着工业安全需求的提升，安全帽检测技术在建筑、电力、矿业等领域的重要性日益凸显。本文针对复杂作业场景下安全帽检测的实时性与准确性挑战，提出了一种基于深度学习与多模态融合的创新方法。采用改进的 YOLOv8 算法作为检测核心，通过嵌入 Swin-Transformer 模型重构主干网络，显著提升了对小尺度、遮挡目标的特征提取能力，并利用时空上下文信息增强检测鲁棒性。检测结果通过动态阈值分类器与多级预警机制（声光警报、工单推送、数据云端同步）联动，实现从“检测”到“预警”的全流程自动化。实验表明，本系统在复杂光照、密集人群及动态遮挡场景下均表现出色，平均检测精度达 95.7%，误报率低于 1.2%，响应延迟小于 0.3 秒，满足工业场景的实时安全管控需求。本文为智能安防技术的落地提供了可复用的技术框架与工程实践参考。

关键词：安全帽检测；预警系统；深度学习；Swin-Transformer；YOLO 目标检测；动态阈值分类

Research and Implementation of Safety Helmet Detection

and Early Warning System

Abstract

With the increasing demand for industrial safety, safety helmet detection technology has become critical in construction, power, mining, and other fields. This paper proposes an innovative method based on deep learning and multi-modal fusion to address the challenges of real-time performance and accuracy in complex working environments. An improved YOLOv8 algorithm is adopted as the detection core, where the Swin-Transformer model is embedded to reconstruct the backbone network. This significantly enhances feature extraction capabilities for small-scale and occluded targets, leveraging spatiotemporal contextual information to improve detection robustness. The detection results are integrated with a dynamic threshold classifier and a multi-level warning mechanism (including audio-visual alerts, work order notifications, and cloud data synchronization), enabling end-to-end automation from "detection" to "warning." Experiments demonstrate that the system achieves outstanding performance in scenarios with complex lighting, dense crowds, and dynamic occlusions, with an average detection accuracy of 98.7%, a false alarm rate below 1.2%, and a response latency under 0.3 seconds, meeting real-time safety management requirements in industrial settings. This study provides a reusable technical framework and engineering practices for the implementation of intelligent security technologies.

Key Words: Safety helmet detection; Early warning system; Deep learning; Swin-Transformer; YOLO object detection; Dynamic threshold classification

5 目录

摘 要.....	1
Abstract.....	2
1 绪论.....	1
1.1 前言.....	1
1.2 课题背景.....	1
1.3 发展概况.....	2
1.3.1 国内发展状况.....	2
1.3.2 国外发展状况.....	3
1.4 本文主要研究工作.....	
1.5 论文写作安排.....	4
1.5.1 章节安排.....	4
2 相关理论基础.....	5
2.1 迁移学习.....	5
2.2 YOLO 目标检测算法.....	6
2.3 数据集.....	6
2.4 Transformer 神经网络模型.....	7
2.4.1 自注意力机制.....	7
2.4.2 多头注意力机制.....	9
2.4.3 前馈神经网络层.....	9
2.5 本章小结.....	12
3 基于深度学习的目标检测模型原理.....	13
3.1 Swim-Transformer 神经网络模型.....	13
3.1.1 结构化注意力模块.....	13
3.1.2 池化操作.....	13
3.1.3 增强的 Winning Signal.....	14
3.2 Swim-Transformer 作为 YOLO 目标检测算法的骨干.....	14
3.2.1 YOLO 目标检测算法的骨干.....	14
3.2.2 Swim-Transformer 作为骨干.....	14
3.3 本章小结.....	15
4 基于深度学习的安全帽检测及预警系统研究与实现.....	16
4.1 模型设计.....	16
4.1.1 检测方法概述.....	16
4.1.1 预警方法概述.....	16
4.1.3 本文模型跟踪实际设计.....	17
4.2 模型实现.....	17
4.2.1 开发测试环境.....	17
4.2.2 系统前后端.....	19
4.2.3 模型训练.....	19
4.2.4 实验分析.....	21
4.3 本章小结.....	24
5 总结与展望.....	25

5.1 总结	25
5.2 未来展望	25
参考文献	26
致 谢	28
2.1.CNN 主干	33
2.2.密集预测任务	33
2.3.自我注意和愿望中的 Transformer	34
2.1.CNN Backbones	45
2.2.Dense Prediction Tasks	46
2.3.Self-Attention and Transformer in Vision	46

1 绪论

1.1 前言

在本文的前言中，本文对目标检测技术的研究背景及其重要性进行了简明扼要的介绍，概述了本文的核心研究内容和整体框架，并明确提出了本文的研究宗旨和价值所在。本文旨在全面剖析目标跟踪技术的当前研究状况及其未来趋势，从而为后续的相关研究打下坚实的基础。

近年来，目标检测技术得到了飞速的发展，并在多个领域显示出其巨大的应用潜力。特别是目标检测预警技术，在军事侦察、安全监控以及灾害救援等多个方面具有不可替代的作用。然而，传统的目标跟踪方法多依赖于人工设计的特征和规则，在复杂多变的场景和目标中显得力不从心，难以实现精准跟踪。幸运的是，随着深度学习的兴起，基于深度学习的目标跟踪方法凭借其卓越的准确性和广泛的适应性，正逐渐成为科研的焦点。

本文的核心目标是开发一种基于深度学习的目标检测技术，以克服传统方法的局限，并显著提升目标跟踪的精确度和稳健性。为此，本文融合了深度学习领域的尖端技术，构建了一个端到端的目标跟踪系统，旨在实现在错综复杂的场景中对多个目标的实时跟踪。

通过本文的深入研究，期望能够为目标检测的创新和发展提供新的视角和解决方案，进一步推动该技术在不同行业中的广泛应用，从而为社会的进步和发展贡献一份力量。同时，也期望通过本文的实验和验证，证明所提出的方法的有效性和优越性，为后续的研究提供参考和借鉴。

1.2 课题背景

根据之前收集的信息汇总可以得知，目标检测技术是一项至关重要的研究领域，它能够在复杂环境下实现对目标的准确监测，提高了在实际应用中的适用性和效率。

深度学习是基于人工智能的一项新兴研究领域，它运用了机器学习算法，能够处理海量数据。通常情况下，深度学习技术的应用旨在揭示样本数据内在的深层规律和结构^[1]，同时可以分析数据在目标节点之间的传输关系^[2]。深度学习技术的应用主要涉及三个方面：神经网络的构建、神经元的编码以及数据样本的预训练。神经网络的结构决定了数据在网络环境中的传输能力，神经元编码则建立了样本数据之间的数值映射关系，而数据样本的预训练则用于评估所选数据是否满足神经网络主机的调取和处理需求^[3]。

在复杂的情况下,目标检测控制可能会受到外界因素的干扰,如航线规划和天气条件。这可能导致目标检测在捕捉目标时出现像素低于预期的情况^[4]。为了应对这些问题,一种基于地空信息融合的目标检测控制系统提出了一种解决方案。该系统强调从目标图像中提取关键点参数,并利用这些信息与常规像素之间的关系,为设备主机制定跟踪操作指令^[5]。然而,尽管这种系统在一定程度上可以改善控制能力,但其应用仍受到一定限制,无法保证目标像素与预设指标的一致性。

1.3 发展概况

1.3.1 国内发展状况

国内的目标检测技术正在蓬勃发展,为了降低网络运行时的延迟,研究人员选择了一种基于 Transformer 的 CNN 模型,并采用 ResNet8 网络作为主干结构。他们使用 Swim-Transformer 模块用来替换 ResNet8 网络中的 2D 卷积层,实现了类似的全局特征提取,同时为了防止模型过拟合,Dropout 层的删除率设置为 0.5 来达到这种效果。

ResNet8 提出了 Shortcut 连接模式,将网络输入和输出的线性层连接起来。这种设计不仅可以解决梯度消失/爆炸问题^[6],还可以减少网络的运行时延,同时又不增加模型的参数数量。

在这个模型中,研究人员还引入了 Transformer 在图像领域的轻量化方法。SETR 模型的自注意力计算复杂度为 $O(n^2)$,这意味着随着图像尺寸的增加,模型的计算复杂程度会直线上升。这对于受限的目标检测任务并不是很好。因此,降低自注意力计算的复杂度变成了目前的研究热点。在文献^[7]中,PVT 方法引入了 SRA 模块,通过卷积的方式缩减了键值序列,这种方法能够很好的减少自注意力计算的复杂程度。

在 PVTv2^[8]中,基于 PVT,研究人员将原有的 SRA 模块的卷积操作替换为平均池化操作,这一操作进一步的降低了自注意力在计算方面的复杂程度。Swim-Transformer 通过其独特的分窗和移窗操作,将原本基于全局的自注意力计算转变为局部自注意力计算,从而将计算复杂度从二次方降低为线性复杂度^[9]。

Blomel 等人^[10]最早提出了 MOSSE 算法,其平均检测速度可达每秒 600 帧,并且在光照变化和目标尺寸变化时依然表现稳定。然而,MOSSE 算法存在一些局限性,如采用线性滤波器进行采样导致整体分类性能一般。接着,Henriques 等人^[11]提出了 CSK 算法,利用循环矩阵的特点,并采用基于核映射的采样方法代替粒子采样。然而,CSK 算法在适应目标尺度变化方面表现较差,且在目标大小变化时跟踪框无法及时调整,同时在目标快速移动时容易出现丢失。最近,Li^[12]提出了 Auto-Track 算法,将空间局部响应图变化作为空间正则化,使得 DCF 能够专注于学习对象的可靠部分,而全局响应图变化则决定了滤波器的更新速度。这种在线自适应学习方法极大地加快了目标跟踪的速度,并在目标检测领域得到

了广泛的实验和应用^[13]。

1.3.2 国外发展状况

国外的目标检测发展呈现稳定成熟且持续增长的趋势。

CNN（卷积神经网络）在目标检测领域的发展中占据了里程碑式的地位，这主要归功于 Ross Girshick 等人的杰出贡献。他们的 R-CNN 算法以选择性搜索算法为核心，这一思想极大地改进了目标检测的效率。具体来说，R-CNN 不再依赖于传统的滑动窗口方法，而是预先通过选择性搜索算法在图像中筛选出潜在的目标区域，从而大幅减少了不必要的计算量。与此前的目标检测方法相比，R-CNN 的一个显著特点是引入了卷积神经网络（CNN）来进行特征提取，这种方法能够更精确、更高效地捕捉图像中的目标特征，进一步提升了目标检测的准确性和效率。

然而，R-CNN 也面临一些挑战。因为每个候选区域都需要进行特征提取，所以导致了大量的重复计算，进而降低了检测速度。此外，R-CNN 的各个阶段是相互独立的，这限制了算法找到全局最优解的能力。

为了克服这些局限，提出了 Fast R-CNN，实现了一个端到端的检测框架。同时，它将 SVM 分类器替换为 softmax 函数，简化了分类过程。此外，Fast R-CNN 将所有特征存储在显卡中，减少了存储空间占用，并显著提高了检测速度。在 VOC2007 数据集上，其训练速度比 R-CNN 快了 10 倍。

尽管 Fast R-CNN 在速度和准确度上都有所提升，但其候选区域生成方法仍依赖于选择性搜索，这在一定程度上限制了其时效性。因此，尽管 Fast R-CNN 是一个优秀的算法，但在追求更高效、更实时的目标检测方面，仍有进一步改进的空间。

在经典的检测算法奠定基础之后，继而也有很多创新算法。例如，Zhang 等人提出了 Dynamic R-CNN 算法^[14]，通过基于统计量的方法自动调整标签分配标准和回归损失函数，从而减少了训练计算的复杂度和额外开销。Shi 等人^[15]提出了 PV-RCNN 算法，将三维体素卷积神经网络和基于 Point-Net 的集合抽象深度融合，从而在点云中准确检测目标的三维坐标，具有较高的精度。Fin 等人^[16]提出了 Center-Point-CVP21 算法，利用关键点检测器检测目标中心，然后回归到 2D 大小、方向和速度等属性，这种检测算法更简单、高效，但在边缘类别的计算设备上的时效性还是有待改进。

1.4 本文主要研究工作

本篇论文的具体研究工作内容为以下四点：

- 查阅了深度学的相关文献，对基于深度学习的视觉方面的发展和现状，尤其是 YOLOv8，算法进行了进一步深入的了解。
- 对 swim-transformer 网络模型架构进行了进一步深入的了解。
- 在 a, b 的研究的基础上对 swim-transformer 网络模型架构作为特征提取融

合进 YOLO 的 backbone 中，其次使用 YOLOv3+DEEPSORT 算法进行目标检测与预警，使其在 python 语言的环境下进行开发并对其进行了参数变化验证。

1.5 论文写作安排

1.5.1 章节安排

本文总共分为五个章节，具体的内容安排如下：

第一章：绪论，本章开篇对基于深度学习的目标检测技术的当前发展状况进行了概述，详细阐述了本文的研究背景和选题动机。同时，明确指出了本论文的研究目的和意义，为后续章节的展开奠定了基础。

第二章：相关技术基础。本章着重介绍了本文所涉及的相关技术基础，为后续章节中跟踪模型的设计和实现提供了理论依据和技术支撑。

第三章：基于深度学习的神经网络模型原理，介绍了本文具体用到的特征提取基础网络模型结构。该模型作为本文研究的核心，其独特的设计思路和高性能在目标跟踪领域具有显著优势。通过对该模型的深入剖析，读者可以更加清晰地理解其工作原理和适用场景。

第四章：安全帽检测及预警系统研究与实现，本章对本文的跟踪方案进行了详细的设计叙述，并对模型的实现进行了讲解。同时，对模型进行了具体的实验分析。

第五章：总结与展望，对本文模型的优点以及缺点进行了简述总结，并对未来进行了展望。

2 相关技术基础

本文的主要研究方案分别涉及以下几个方面：迁移学习；YOLO 目标检测算法；数据集的选用；Transformer 网络模型。当然还有一些其他的研究方面，这些方面代表了深度学习领域当前的主要研究趋势，同时也反映了学术界和工业界对于解决实际问题 and 推动技术发展的关注点。以下将逐个介绍几个与本文息息相关的内容。

2.1 迁移学习

迁移学习的核心思想是把一个任务中学到的知识经验应用到另一个相似但不同的任务中，这样可以提高目标任务的学习效率和性能。这种机器学习技术特别适用于那些标记数据稀缺或难以获取的场景。

迁移学习的主要动机是因为数据稀缺性，当目标任务缺乏足够的标记数据时，迁移学习可以从相关且数据丰富的源任务中借用知识，从而减少对新数据的依赖。在领域适应方面，源领域和目标领域之间可能存在数据分布、特征表示等方面的差异。迁移学习旨在通过识别和利用这些领域之间的共性，使模型能够更好地适应目标领域，并提高泛化能力。在任务相关性方面，即使源任务和目标任务的输入和输出空间不完全相同，只要它们之间存在某种程度的相似性或相关性，迁移学习就可以利用这种关系来加速目标任务的学习过程。

迁移学习这种方法是解决深度学习中的数据不足和训练时间长问题的有效手段。它可以通过以下几种策略来实现。特征提取器迁移是指，将一个已经在源任务上训练好的特征提取器迁移到新的目标任务中，这个过程其实是在重用源任务学到的知识和经验。这种迁移的方式允许利用在源任务上获得的优质特征表示，作为新任务的起点。随后，可以根据目标任务的特定需求和数据特点，对迁移过来的特征提取器进行微调。模型微调是在特征提取器迁移学习的基础上，通常会对整个网络架构（包括预训练的特征提取器和后续的层）进行进一步训练和调整，这个过程被称为“模型微调”。通过微调，模型能够学习到与目标任务数据分布更匹配的参数，这样可以提高在数据集上的性能。领域适应：针对源领域和目标领域之间的差异，采用特定的技术（如对抗训练或领域对抗神经网络）来减小这些差异，使模型在目标领域上表现更好。最后就是多任务学习，多任务学习就是同时学习多个任务，知识共享通过分享部分参数来实现。这种方法可以在相似的任务之间传递知识，从而提高每个任务的性能。多任务学习通常与迁移学习结合使用，以充分利用不同任务之间的互补性。

本论文使用的方法即为特征提取器迁移。

2.2 YOLO 目标检测算法

YOLO (You Only Look Once) 算法家族中的最新成员 YOLOv8, 是目前炙手可热的目标检测算法。其核心理念在于将复杂的目标检测过程简化为一个神经网络的单一前向传递, 从而实现了既高效又高精度的实时检测。相比于传统方法, YOLOv8 通过这种创新的方式极大地提升了检测速度和准确性。

YOLOv8 作为 YOLOv5 的继任者, 继承了前者的成功精髓, 并在此基础上进行了大量的优化和增强。这个新版本不仅在设计上更加巧妙, 而且在实际应用中表现出更高的精度和易用性。这些优势使得 YOLOv8 在物体检测、跟踪、语义分割、图像分类以及姿态估计等任务中, 成为了研究人员和开发者的首选工具。无论是在性能还是在实用性上, YOLOv8 都展现出了其独特的魅力和价值。

2.3 数据集

本模型的目标旨在跟踪不同环境场景下的人物安全帽模型, 使用 <https://app.roboflow.com/> 下寻找到数据集, 包含有头盔和无头盔的两种类别标签。




图 2.3.1 数据图片

txt 文档内容分别为数据标签, 标记框 x 轴, 标志框 y 轴, 高度, 以及宽度。



图 2.3.2 标签内容

2.4 Transformer 神经网络模型

传统的 Transformer 模型是指 Vaswani 等人在 2017 年提出的原始 Transformer 模型。该模型最开始被用于机器翻译任务，但后来通过大量实验可知其在各种机器学习领域内效果不菲。

Transformer 模型基于自注意力机制，它能够在输入序列中找到相关的信息，而无需依赖序列的顺序。这使得模型能够并行计算，因为每个单词的表示都可以同时计算，而不受序列长度的影响。

2.4.1 自注意力机制

自注意力机制，作为 Transformer 模型的核心所在，赋予了模型一种跨越整个序列的“全局洞察力”。与以往的序列处理模型不同，自注意力机制使得模型在处理序列中的任何一个元素时，都能同时吸收和利用序列中其他所有元素的信息。这种能力让模型能够全面而准确地捕捉序列内部的各种依赖关系，无论这些关系是在元素之间相隔较远还是较近。

在实现上，自注意力机制巧妙地利用了查询向量（Query）、键向量（Key）和数值向量（Value）这三种不同但相互关联的向量。简单来说，当您关注某个特定的元素时（即 Query），会查看序列中所有的其他元素（即 Keys），并计算出 Query 与每个 Key 之间的相关性。这个相关性实际上就决定了对每个 Value 的“注意力”程度，即给予每个 Value 多大的权重。

通过这种方式，自注意力机制实现了对序列中每个元素的“个性化”关注，使得模型能够根据上下文信息来动态地调整对每个元素的重视程度。这种灵活性和全局性使得 Transformer 模型在许多自然语言处理任务中都取得了显著的性能提升。




图 2.1 注意力权重分配

在注意力机制的运行过程中，虽然 Query、Key 和 Value 这三者各自占据不同的向量空间，但它们之间存在着一种内在的、微妙的联系。这种联系使得它们可以通过某种数学变换，被映射到一个共同的、相似的空间里，以便进行比较和运算。

在开始计算注意力时，首先需要将 Query、Key 和 Value 这些输入准备好。随后，一个关键的步骤是利用 Query 和 Key 之间的某种关联性或相似性来度量它们之间的“亲近度”。这种“亲近度”通常通过一个分数或权重来表示，称之为注意力得分。

这个注意力得分实际上是 Query 和 Key 之间关系的一种量化表达。它反映了在给定的任务或场景下，Query 对 Key 中蕴含信息的依赖程度。得到了注意力得分之后，就可以用它来对 Value 进行加权处理。具体来说，就是将 Value 与相应的注意力得分相乘，以突出或削弱其在最终输出中的重要性。

注意力机制通过这种方式，实现了对信息的精确选择和有效利用，极大地增强了模型在处理复杂任务时的效率和准确性。它允许模型专注于那些对任务至关重要的信息，从而提高了整体性能。

点积: $\text{Similarity}(\text{Query}, \text{Key}_i) = \text{Query} \cdot \text{Key}_i$ (1)

Cosine 相似性: $\text{Similarity}(\text{Query}, \text{Key}_i) = \frac{\text{Query} \cdot \text{Key}_i}{\|\text{Query}\| \cdot \|\text{Key}_i\|}$ (2)

MLP 网络: $\text{Similarity}(\text{Query}, \text{Key}_i) = \text{MLP}(\text{Query}, \text{Key}_i)$ (3)

其在目标检测或注意力机制的应用中，会对计算出的注意力得分（通常是一系列浮点数）进行处理，以确保其能更好地体现各个元素之间的相对重要性。具体来说，会对这些得分进行缩放处理，该处理通常分为两步：

得分缩放：首先，将每个得分除以一个与维度相关的值（通常是维度的平方根）。这个步骤的目的是为了调整得分的幅值，防止在后续使用 softmax 函数时，由于得分过大或过小而导致的问题。通过除以维度的平方根，可以使得得分的分布更加均匀，便于后续的处理。

在应用缩放操作之后，我们进一步利用 softmax 函数来处理数据。这个函数的作用是将一组实数转换为一个概率分布，也就是说，它会确保转换后的每个数

值都落在 0 至 1 的区间内,并且这些数值的总和恰好为 1。通过这种方式,softmax 函数能够帮助我们将原始数据规范化,便于后续的数据分析和处理。在注意力机制中,这些输出值可以视为不同元素或位置被选中的概率,其中较大的值表示该元素或位置在后续计算中应该被赋予更高的权重。

通过这两步处理,既可以利用 softmax 函数的特性来突出重要元素的权重,又可以通过归一化来确保权重之和为 1,形成一个合理的概率分布。这样处理后的得分可以作为后续计算的输入,如加权求和等,以实现目标检测或注意力机制的功能。通常采用以下公式进行计算:

$$a_i = \text{Softmax}(Sim_i) = \frac{e^{Sim_i}}{\sum_{j=1}^{L_x} e^{Sim_j}} \quad (4)$$

最后,根据生成的权重系数对 Value 值进行加权和求和,最终就可以得到 Attention Value。

$$\text{Attention}(Query, Source) = \sum_{i=1}^{L_x} a_i \cdot Value \quad (5)$$

2.1.2 多头注意力机制

Transformer 模型通过引入多头注意力机制,显著增强了其表达和学习能力。多头注意力机制的核心思想是并行处理多组查询、键和值的投影,从而捕获并学习到多种不同的注意力分布。这些不同的注意力分布,或称为“头”,为模型提供了更丰富的表示手段。

在实际应用中,希望模型能够灵活捕捉序列数据中的多种依赖关系,包括短距离和长距离的联系。为此,多头注意力机制允许查询、键和值在不同的子空间中进行表示,并通过这些子空间学习到不同的行为模式。这种设计使得模型能够更全面地理解数据中的复杂关系。




图 3.1.2 多头注意力图

在具体实现上,Transformer 模型使用了多组独立的线性投影来转换原始的查询、键和值。这些经过转换的向量被分别输入到多个并行的注意力机制中,每个注意力机制都会生成一个独立的注意力权重分布。接着,这些分布的输出会被拼接在一起,并通过一个额外的线性变换进行融合,最终得到模型的输出。

2.4.3 前馈神经网络层

除了自注意力层之外，Transformer 模型还包含前馈神经网络层。通过两个线性变换层和一个激活函数来处理每个位置的表示。

深度学习网络可以将目标检测设备接收到的数据参数提供给系统处理主机，并且通过过渡层节点的作用，可以改变其传入信息的传输格式^[17]，使得系统所使用的跟踪方法可以适应实际的需求^[18]。在实际应用场景中，拍摄设备作为数据的源头，通过其搭载的各类传感器和接入设备，持续不断地捕获并收集关于目标对象的各类数据信息。这些信息种类丰富、形式多样，可能包括目标的位置、速度、方向、大小等多种特征。为了满足这种多样性和变化性，输入层节点必须具备卓越的数据存储能力，确保能够准确、高效地接收和存储这些来自目标检测的数据。一旦数据被输入层节点成功接收和存储，过渡层节点便发挥其关键作用，主要负责将这些从目标检测设备收集到的目标信息，以合适的方式和格式，准确无误地传递到输出层节点。这一传递过程不仅确保了信息的完整性和准确性，也为后续的任务处理和分析打下了坚实的基础。

简而言之，输入层节点是数据的接收和存储中心，过渡层节点则是信息的传递桥梁，它们共同构成了数据处理流程中的重要环节，为目标检测等应用提供了有力的支持。输出层节点对应系统处理主机，负责将目标跟踪指令反应给其他的应用设备^[19]。




图 3.1.3 前馈神经网络图示

神经网络的核心组成部分是神经网络层，它们是由多个神经元（或称为计算节点）构建而成的。这些神经元扮演着信息处理器的角色，它们从上一层的神经元接收输入信号，通过内部计算机制生成输出信号，并将这些输出传递给下一层的神经元。在神经元之间的连接中，存在一个重要的参数称为权重，这些权重决定了输入信号对神经元最终输出的影响程度。在前馈神经网络中，网络层可以划分为三种主要类型：

输入层（Input Layer）:这一层是神经网络与外部世界的接口，直接接收来自外部环境的原始数据。**隐藏层（Hidden Layer）**:隐藏层位于输入层与输出层之间，不与外界直接交互。它们通过神经元对输入信号进行加权和激活函数的非线性变换，以捕获数据的内在规律和特征。隐藏层可以包含多个层级，每层中的神经元数量和它们之间的权重都是通过学习过程来确定的。**输出层（Output Layer）**:输出层是神经网络信息的最终输出界面，它接收来自上一层（通常是最后一层隐

藏层)的处理结果,并据此产生整个网络的最终输出结果。输出层的神经元数量与所要解决的具体任务类型紧密相关。例如,在分类任务中,输出层的神经元数量通常与要区分的不同类别数量相匹配,每个神经元对应一个可能的类别,通过其激活程度来反映输入数据属于该类别的概率或置信度。

此外,神经网络还可以根据层数的多少分为单层神经网络和多层神经网络。单层神经网络较为简单,只包含输入层和输出层;而多层神经网络则包含多个隐藏层,单层的神经网络是最简单的一种,只包含一个输出层,其输入到最终的变化关系为:

$$s_j = \sum_{i=1}^n w_{ji} x_i - \theta_j \quad (6)$$

$$y_j = \begin{cases} 1, s_j \geq 0 \\ 0, s_j < 0 \end{cases} \quad (7)$$

上式中, $x=[x_1, x_2, \dots, x_n]$ 是输入特向量, w_{ji} 是 x 到 y 的连接权, f 是激活函数,输出量 y 是按照不同特征分类的结果。

多层前馈神经网络(也称为深度前馈网络或前馈神经网络)的结构通常包含一个输入层、一个或多个隐藏层以及一个输出层。这些层次之间通过权重连接,形成了一种复杂的信息处理系统。

在本文中,我们详细探讨了多层感知机(MLP)这一常见的前馈神经网络结构中的输入与输出之间的变换机制。具体来说,输入层的神经元负责接收外部输入的原始数据,随后这些数据会依次流经隐藏层中的神经元,经历一系列复杂的非线性变换。在隐藏层中,每个神经元都会对输入数据进行加权求和,并应用一个激活函数(如 Sigmoid、ReLU 等),以实现数据的非线性处理。这一过程会在网络的各个隐藏层中重复进行,直到数据最终到达输出层。

在输出层,神经元的输出代表了整个网络对输入数据的最终预测或分类结果。这些输出是基于输入数据在隐藏层中经过多次变换和深度处理的结果。因此,本文中的多层感知机通过其独特的层次结构和神经元间的连接权重,定义了一种高度复杂的非线性输入与输出之间的关系。

在多层感知网络中,输入与输出的变换关系为。

$$s_i^{(q)} = \sum_{j=0}^{n_{q-1}} w_{ij}^{(q)} x_j^{(q-1)}, (x_0^{(q-1)} = \theta_i^{(q)}, w_{i0}^{(q-1)} = -1) \quad (8)$$

$$x_i^{(q)} = f(s_i^{(q)}) = \begin{cases} 1, s_i^{(q)} \geq 0 \\ -1, s_i^{(q)} < 0 \end{cases} \quad (9)$$

$$i = 1, 2, \dots, n_q; j = 1, 2, \dots, n_{q-1}; q = 1, 2, \dots, Q \quad (10)$$

前馈神经网络通过层级间的连接以及每层之间的权重来学习并理解输入数据的内在特征。为了缩小网络预测结果与实际结果之间的差距,该网络会利用优化技术(如梯度下降法)来微调这些权重,从而不断提高其预测准确性。这一过

程旨在减少预测误差，使神经网络的输出更加贴近真实情况。

2.5 本章小结

第二章主要介绍了本文相关的一些技术基础。这些方向不仅在学术界受到广泛关注，也在实际应用中具有重要的价值和意义。

3 基于深度学习的目标检测模型原理

Transformer 神经网络模型往往被用来作为序列建模的深度学习模型，擅长处理自然语言处理任务。Transformer 模型的传统核心思想是基于自注意力机制（Self-Attention Mechanism），Transformer 模型在处理长序列数据时比于传统的循环神经网络（RNN）或者卷积神经网络（CNN），具有更好的性能。

3.1 Swin-Transformer 神经网络模型

Swin-Transformer（Structured Winning Modulation for Transformer）是一种针对 Transformer 架构进行改进的神经网络模型。它的设计目标是在保持 Transformer 优点的同时，改进对长距离依赖性的建模和性能。




图 3.2.1 Swin-Transformer 模型

3.1.1 结构化注意力模块

Swin-Transformer 引入了结构化共享模块，以改进 Transformer 中的自注意力机制。传统的自注意力机制在处理长距离时可能受到限制，因为它整个连接的共享模型，每个位置都会与彼此进行交互。

结构化沟通模块通过建立结构化的沟通模式，限制了每个位置之间的交互，使每个位置仅与最重要的位置进行沟通计算。必须减少计算复杂度，并提高模型对长距离依赖的建模能力。

3.1.2 池化操作

Swin-Transformer 中的池化操作是一种新颖的机制，用于处理不均匀长度的序列数据。传统的池化操作通常会丢失输入序列中的信息，尤其是对于长度不一的序列。而 Swin-Transformer 中的池化操作允许网络动态地聚合输入序列中的信息，而不需要将其强制调整为相同的长度。

Swin-Transformer 中的池化操作分为两个步骤：

加权池化（Weighted Pooling）：首先，对输入序列中的每个元素应用一个

可学习的权重函数，将其转换为具有不同重要性的表示。这个权重函数可以是一个神经网络层，根据输入的上下文动态地计算每个元素的权重。

汇聚操作（Aggregation）：然后，根据计算得到的权重，对加权后的元素进行汇聚操作，生成最终的池化表示。这个汇聚操作可以是简单的加权平均或加权求和，也可以是其他更复杂的汇聚方式，以适应不同的任务和数据特点。

Swim-Transformer 通过其独特的池化机制，在维护输入序列信息完整性的同时，实现了对长短不一的序列数据的灵活处理。这种设计不仅增强了模型的泛化能力，还提高了模型在面对不同场景和条件时的适应性。

3.1.3 增强的 Winning Signal

Swim-Transformer 还引入了增强的 Winning Signal，用于指导模型选择正确的焦点区域。这可以作为一种正则化机制，帮助提高模型的泛化能力和学习效果。

3.2 Swim-Transformer 作为 YOLO 目标检测算法的骨干

3.2.1 YOLO 目标检测算法的骨干

Darknet-53 是 YOLOv3 中使用的骨干网络，由 Joseph Redmon 提出。它具有以下特点：在网络深度方面，Darknet-53 包含 53 个卷积层，这些层用于从输入图像中提取特征。它的残差结构网络采用了残差连接（residual connections），这种设计可以有效地提高模型的训练速度和精度。在卷积核大小方面主要使用 3x3 的卷积核，与更大的卷积核相比，它可以显著减少参数数量，加速模型训练和推理。更换骨干网络对 YOLO 的性能和效果会产生显著影响。不同的骨干网络具有不同的特点和优势，因此选择适合当前任务和数据集的骨干网络至关重要。一般来说，更深的网络可以提取更丰富的特征，但也可能导致过拟合和计算复杂度的增加。而轻量级的网络则可以在保持较高精度的同时降低计算复杂度和模型大小，适用于移动设备和边缘计算等场景。

选择合适的骨干网络是构建高效、准确的 YOLO 模型的关键步骤之一。在实际应用中，需要根据具体的需求和场景来选择合适的骨干网络。

3.2.2 Swim-Transformer 作为骨干

本文旨在基于 YOLOv8 的基础上，使用 Swim-Transformer 将 YOLOv8 的主干网络替换，可以达到更好的长程依赖建模，Swim-Transformer 是一种专门设计用于处理长距离依赖性的 Transformer 架构。相比于传统的卷积神经网络，Transformer 在捕捉长程依赖方面表现更好，这可能有助于改善 YOLOv8 在复杂场景下的性能。同时，会获得更好的多尺度特征提取。Swim-Transformer 在设计上考虑到了多尺度特征的提取，通过分层的注意力机制和局部感知机制来有效地捕获图像中不同尺度的特征信息。这可以帮助 YOLOv8 在处理不同大小的目标时更加准确。在这之上，会获得更好的参数效率。相比于传统的卷积神经网络，

Transformer 架构在参数使用上更加高效，尤其是在处理大型输入图像时。这可能会减少模型的参数数量，提高模型的训练速度和推理速度。最后，这样可以使得模型有更好的迁移学习性能。Swim-Transformer 作为一种通用的特征提取器，可以在不同的视觉任务中进行迁移学习。通过使用 Swim-Transformer 作为 YOLOv8 的主干网络，可以借助其在大规模图像数据上预训练的特征表示，从而提高 YOLOv8 在各种视觉任务上的性能。

实验结果分析与验证：对实验结果进行分析和验证，比较同模型下的公开数据集的性能差异，探讨可能的改进空间和未来研究方向。

模型的具体构建：首先从网络下载 YOLOv8 整体模型框架，对其进行更改，打开 YOLOv8 的网络框架。首先调整输入输出结构，YOLO 通常期望输入是图像，并且输出是一系列边界框和类别预测，因此，需要将 Swim-Transformer 的输入输出结构调整符合 YOLO 的要求确保 Swim-Transformer 的输出与 YOLOv8 的后续网络结构（如 Neck 和 Head）相匹配。可能需要添加适当的预处理和后处理步骤，需要对网络的特征图的尺寸和通道数进行调整，以确保输入输出与 YOLO 兼容。其次需要转换模型架构，Swim-Transformer 的架构与传统的 CNN 不同，可能需要对其进行适当的转换，以便作为 YOLO 的骨干使用。这可能涉及将 Swim-Transformer 的层替换为卷积层或者与 YOLO 兼容的结构。需要确保转换后的模型能够有效地提取图像特征，并适应 YOLO 的预测需求。最后需要调整训练和优化策略。

图示为更改后的 YOLOv8 的主干网络。

```
# YOLOv8.0n backbone
backbone:
  # 0 [from, repeat, module, args]
  # -1, 1, Conv, [64, 3, 2] # 1-P1/2
  # -1, 1, Conv, [128, 3, 2] # 1-P2/4
  # -1, 1, Conv, [256, 3, 2] # 1-P3/8
  # -1, 1, Conv, [512, 3, 2] # 1-P4/16
  # -1, 1, Conv, [1024, 3, 2] # 1-P5/32
  # -1, 1, SPPF, [1024, 5] # 9
  # [from, number, module, args]
```

图 3.2.1 YOLOv8 原本骨干网络

```
# YOLOv8.0n backbone
backbone:
  # 0 [b, 96, 16, 16]
  # -1, 1, PatchEmbed, [96, 4] # 0 [b, 96, 16, 16]
  # -1, 1, SwinStage, [96, 2, 3, 7] # 1 [b, 96, 16, 16]
  # -1, 1, PatchMerging, [192] # 2 [b, 192, 8, 8]
  # -1, 1, SwinStage, [192, 2, 6, 7] # 3 [b, 192, 8, 8]
  # -1, 1, PatchMerging, [384] # 4 [b, 384, 4, 4]
  # -1, 1, SwinStage, [384, 6, 12, 7] # 5 [b, 384, 4, 4]
  # -1, 1, PatchMerging, [768] # 6 [b, 768, 2, 2]
  # -1, 1, SwinStage, [768, 2, 24, 7] # 7 [b, 768, 2, 2]
```

图 3.2.2 替换后的主干网络

3.3 本章小结

第三章简要介绍了 Swim-Transformer 神经网络模型。引入了加权注意力和多头自注意力机制，处理不均勻长度序列。同时介绍了如何将 Swim-Transformer 作骨干融入 YOLOv8 目标检测算法。为后续模型建立提供准备。

4 基于深度学习的安金帽检测及预警系统研究与实现

4.1 模型设计

4.1.1 检测方法概述

总的来说，该流程的核心是使用改用 Swim-Transformer 作为主干网络的 yolo v8 模型进行目标检测，通过这种方式，可以实现对目标在视频或者图片中的实时检测，从而实现对其行为的监测和分析。

目标检测：使用 Swim-Transformer 作为主干网络的 yolo v8 模型进行目标检测。对于每一帧图像，通过 Swim-Transformer 模型进行前向推理，检测图像中的目标物体。

特征提取：对于每个检测到的目标，提取特征向量。这些特征向量是 Swim-Transformer 模型中的输出，包含了目标的语义信息和空间信息。

结果输出：将最终的结果输出到界面中。

4.1.1 预警方法概述

实时检测与分类：

系统通过 YOLO 模型对输入图像/视频帧进行实时检测，识别两类目标：戴安全帽（标签 0）和未戴安全帽（标签 1）。模型输出检测框坐标及分类结果。通过统计两类标签数量判断安全状态。

动态阈值预警：

当检测到未戴安全帽人数（标签 1） ≥ 1 时立即触发预警机制。系统通过 GUI 界面实时更新状态提示：用红色文字显示“预警”及未戴人数，安全状态下则显示绿色“安全”提示。预警阈值设置为刚性零容忍策略。

可视化证据留存：

对每个未戴安全帽的检测目标，截取对应区域图像（200x200 像素）显示在预警面板，形成违规证据链。同时将原始画面添加检测框（红色-违规，蓝色-合规）后展示在主画布，实现检测结果可视化。

数据持久化记录：

每次检测生成包含时间戳、文件源、人数统计及状态标记的结构化记录，存储至